

Relatório — Análise da Base Copa do Mundo FIFA (1930–2014)

Este relatório resume, em linguagem simples, os principais achados da análise exploratória realizada sobre 850 partidas de Copas do Mundo, de 1930 a 2014.

1. Quais são os principais padrões encontrados?

O futebol é um esporte de placar baixo: a maioria das partidas termina com 1 a 3 gols no total, e goleadas são raras. Times mandantes marcam, em média, quase o dobro de gols dos visitantes (1,8 contra 1,0), o que confirma a conhecida 'vantagem de jogar em casa'. O público cresceu de forma constante entre as décadas de 1930 e 1980, estabilizando-se depois — hoje os estádios já operam próximos de sua capacidade máxima nas fases decisivas. Partidas de fase eliminatória (mata-mata) atraem mais público que jogos de fase de grupos, mas não necessariamente têm mais gols — muitas vezes são jogos mais cautelosos e disputados.

2. Quais variáveis merecem maior atenção ou cuidado analítico?

A coluna de público (Attendance) precisa de cuidado ao comparar diferentes fases e décadas, pois seu comportamento muda bastante conforme o contexto — não deve ser tratada como uma medida única e uniforme. Os gols marcados no intervalo (1º tempo) estão fortemente ligados ao placar final, então não devem ser usados junto com o placar final em modelos preditivos, sob risco de dupla contagem da mesma informação. A coluna que descreve a condição de vitória (Win.conditions) mistura texto livre com o nome do time vencedor, dificultando seu uso direto — precisaria ser reorganizada em campos separados antes de qualquer análise mais aprofundada.

3. Existem grupos distintos/claros de observações?

Sim. Três grupos se destacam claramente: (1) partidas de fase de grupos versus fase eliminatória, que têm perfis de público muito diferentes; (2) Copas do Mundo mais antigas (1930-1966), com jogos de placar mais elevado e disperso, versus Copas mais recentes (1998-2014), com jogos mais equilibrados e defensivos; e (3) um pequeno grupo de partidas históricas de goleada (como Hungria 10x1 sobre El Salvador, em 1982) que se destacam como eventos extremos genuínos, e não erros de digitação.

4. Existem problemas críticos de qualidade nos dados que impactam as conclusões?

Sim, dois problemas relevantes foram identificados. Primeiro, 15 partidas da Copa de 2014 estão duplicadas na base (30 linhas repetidas), o que, se não corrigido, infla artificialmente as estatísticas dessa edição. Segundo, mesmo após remover as duplicatas, a Copa de 2014 permanece com uma partida a menos do que o esperado para o formato de 32 seleções, sugerindo um registro ausente. Ambos os problemas foram tratados na análise removendo as duplicatas antes dos cálculos, mas é importante documentá-los, pois afetam diretamente qualquer contagem ou média que envolva a edição de 2014.

5. Quais análises preditivas ou estudos futuros poderiam ser realizados?

A base permite, por exemplo: (a) construir um modelo preditivo do resultado da partida (vitória do mandante, empate ou vitória do visitante) usando histórico de confrontos e fase da competição; (b) modelar o público esperado em função do estádio, fase e seleções envolvidas, útil para planejamento operacional de eventos; (c) cruzar esta base com dados externos de PIB, população ou distância de viagem das seleções, para investigar fatores socioeconômicos associados ao desempenho; e (d) uma análise de séries temporais mais aprofundada sobre a queda na média de gols ao longo das décadas, testando hipóteses táticas ou regulatórias (mudanças de regras, evolução física dos atletas).