

Trabalho Final — Análise Exploratória de Dados

Base de dados: FIFA World Cup 1930–2014

Disciplina: Análise Exploratória de Dados — UNIFEI — 2026.1

Etapa 1 — Entendimento dos Dados

1.1 Contexto e objetivo da coleta

A base reúne o histórico completo de partidas oficiais da Copa do Mundo FIFA, cobrindo 20 edições, de 1930 (Uruguai) a 2014 (Brasil), totalizando 850 registros de jogos. Cada linha representa uma partida e traz informações sobre local, equipes, placar, público e arbitragem. O objetivo provável da coleta é permitir análises históricas e estatísticas sobre o desempenho de seleções, a evolução do público nos estádios, os formatos de disputa (fases de grupo, mata-mata) e características das partidas ao longo de quase um século de torneios.

1.2 Descrição e classificação das variáveis

Variável	Descrição	Classificação
Year	Ano de realização da Copa	Quantitativa discreta
Datetime	Data e hora da partida	Qualitativa nominal (data/hora)
Stage	Fase da competição (grupo, oitavas, final...)	Qualitativa ordinal
Stadium	Nome do estádio	Qualitativa nominal
City	Cidade sede da partida	Qualitativa nominal
Home.Team.Name	Nome da equipe mandante	Qualitativa nominal
Away.Team.Name	Nome da equipe visitante	Qualitativa nominal
Home.Team.Goals	Gols marcados pelo mandante	Quantitativa discreta
Away.Team.Goals	Gols marcados pelo visitante	Quantitativa discreta
Half.time.Home.Goals	Gols do mandante no intervalo	Quantitativa discreta
Half.time.Away.Goals	Gols do visitante no intervalo	Quantitativa discreta
Attendance	Público presente no estádio	Quantitativa contínua
Win.conditions	Condição de desempate (pênaltis, prorrogação)	Qualitativa nominal
Referee / Assistant.1/2	Árbitro e assistentes	Qualitativa nominal
RoundID / MatchID	Identificadores internos da rodada/partida	Qualitativa nominal (código)
Home/Away.Team.Initials	Sigla de 3 letras da seleção	Qualitativa nominal

Observação: *RoundID* e *MatchID* são numéricos apenas em formato, mas funcionam como códigos identificadores (chaves), não como quantidades — por isso são tratados como qualitativos nominais. A variável *Stage* é ordinal porque existe uma ordem lógica de progressão no torneio (fase de grupos → oitavas → quartas → semifinal → final).

Etapa 2 — Auditoria dos Dados

```
# Valores ausentes
print(df.isnull().sum())

# Duplicados
print(df.duplicated().sum())
print(df.duplicated(subset=["MatchID"], keep=False).sum())

# Inconsistências: gols do intervalo maiores que gols finais
inc_home = df[df["Half.time.Home.Goals"] > df["Home.Team.Goals"]]
inc_away = df[df["Half.time.Away.Goals"] > df["Away.Team.Goals"]]

# Outliers de público via IQR
q1, q3 = df["Attendance"].quantile([0.25, 0.75])
iqr = q3 - q1
lim_sup = q3 + 1.5*iqr
outliers = df[df["Attendance"] > lim_sup]
```

2.1 Valores ausentes

Não há valores nulos (NaN) em nenhuma das 21 colunas. Isso é comum em bases históricas consolidadas manualmente por curadores, mas não significa ausência de problemas de qualidade — como mostram os itens seguintes, dados 'preenchidos' podem ainda assim estar incorretos ou duplicados.

2.2 Registros duplicados

Uma checagem ingênua de linhas idênticas (`df.duplicated()`) não encontra nenhuma duplicata, pois a coluna 'Unnamed: 0' funciona como índice sequencial único. Entretanto, ao verificar duplicidade pelo identificador de partida (`MatchID`) — a chave real do jogo — encontramos 15 partidas duplicadas (30 linhas), todas concentradas na Copa de 2014. Comparando essas linhas em todas as demais colunas, elas são idênticas byte a byte, confirmando tratar-se de erro de carga/exportação dos dados, e não de jogos remarcados. Além disso, mesmo após a remoção das duplicatas, a Copa de 2014 registra apenas 63 partidas únicas, quando o formato de 32 seleções (igual ao de 1998–2010) deveria produzir 64 jogos — indício de que ao menos uma partida está ausente da base.

Estratégia recomendada: remover as 30 linhas duplicadas mantendo apenas uma ocorrência por `MatchID` (`df.drop_duplicates(subset='MatchID')`), e documentar a partida faltante de 2014 como limitação conhecida da base.

2.3 Inconsistências lógicas

Foi testado se o placar do intervalo (`Half.time.Goals`) poderia superar o placar final — o que seria logicamente impossível, já que o placar final é cumulativo. Nenhuma inconsistência desse tipo foi encontrada, sugerindo boa integridade referencial entre essas colunas. Também não há valores de público iguais a zero ou negativos. Outra inconsistência textual notada informalmente: a coluna `Win.conditions` mistura, na mesma coluna, o nome do vencedor com a condição de vitória (ex.: 'Germany FR win on penalties (4-1)'), dificultando o uso direto da coluna — o ideal seria separá-la em duas variáveis: 'vencedor_desempate' e 'tipo_desempate'.

2.4 Outliers

Pelo critério de $1,5 \times \text{IQR}$, 10 partidas apresentam público acima do limite superior (~108 mil espectadores), quase todas jogos disputados no Estádio Azteca (México) ou no Maracanã (Brasil), estádios historicamente com capacidades excepcionais — não são erros de digitação, mas valores extremos genuínos, refletindo a realidade desses locais. Já em número de gols, três partidas se destacam como candidatas a outlier: Hungria 9x0 Coreia do Sul (1954), Iugoslávia 9x0 Zaire (1974) e Hungria 10x1 El Salvador (1982). São goleadas históricas documentadas e reais, portanto devem ser mantidas na análise — outliers legítimos não devem ser removidos, apenas sinalizados, pois representam eventos extremos verdadeiros e não erros de medição.

Etapa 3 — Análise Univariada

```
num_vars = ["Home.Team.Goals", "Away.Team.Goals", "Attendance",
            "Half.time.Home.Goals", "Half.time.Away.Goals"]

resumo = pd.DataFrame({
    "media": df[num_vars].mean(),
    "mediana": df[num_vars].median(),
    "moda": df[num_vars].mode().iloc[0],
    "variância": df[num_vars].var(),
    "desvio_padrao": df[num_vars].std(),
    "cv_%": df[num_vars].std()/df[num_vars].mean()*100,
    "assimetria": df[num_vars].skew(),
    "q1": df[num_vars].quantile(.25),
    "q3": df[num_vars].quantile(.75),
})

sns.histplot(df[col], kde=True) # para cada variável
sns.boxplot(y=df[col])
```

Variável	Média	Mediana	Moda	DP	CV%	Assimetria	Q1	Q3
Gols Mandante	1,81	2	1	1,61	89%	1,12	1.0	3.0
Gols Visitante	1,02	1	0	1,09	107%	1,25	0.0	2.0
Público	45.165	41.580	—	23.485	52%	0,68	30000.0	61374.5
Gols 1ºT Mandante	0,71	0	0	0,94	132%	1,58	0.0	1.0
Gols 1ºT Visitante	0,43	0	0	0,69	161%	2,01	0.0	1.0

3.1 Histogramas




Figura 1 — Distribuições das variáveis numéricas principais.

Todas as variáveis de gols são fortemente assimétricas à direita (assimetria positiva entre 1,1 e 2,0): a maioria das partidas tem poucos gols (0 a 2) e uma cauda longa de jogos com goleadas raras. Isso é típico de contagens em esportes de baixo placar, como o futebol, onde marcar muitos gols é um evento pouco frequente. Os gols no intervalo (1º tempo) são ainda mais concentrados em zero, com assimetria mais acentuada, pois metade do jogo ainda não ocorreu. O público (Attendance) tem distribuição mais próxima da normal, porém também levemente assimétrica à direita, com uma cauda de estádios lotados (Azteca, Maracanã).

3.2 Boxplots




Figura 2 — Boxplots de gols do mandante, visitante e público.

Os boxplots confirmam visualmente a assimetria: as caixas são 'empurradas' para valores baixos com diversos pontos além do bigode superior (goleadas). O time mandante concentra mais outliers de gols que o visitante, sugerindo vantagem ofensiva de jogar em casa — fenômeno conhecido no futebol como 'vantagem de mando de campo'. O boxplot de público mostra dispersão maior e outliers claros de estádios excepcionalmente cheios.

Etapa 4 — Análise Bivariada

```
corr = df[num_vars].corr()
sns.heatmap(corr, annot=True, cmap="RdBu_r", center=0)

sns.scatterplot(data=df, x="Home.Team.Goals", y="Away.Team.Goals")
sns.scatterplot(data=df, x="Year", y="Attendance")
```




Figura 3 — Matriz de correlação linear (Pearson).




Figura 4 — Gols do mandante x gols do visitante.




Figura 5 — Evolução do público ao longo das edições.

A correlação mais forte da base ($r \approx 0,73$) ocorre entre Gols do Mandante no tempo total e no intervalo — o que é natural, já que o placar final é construído a partir do parcial. O mesmo padrão se repete, um pouco mais fraco, para o visitante ($r \approx 0,69$). Fora essas relações 'estruturais' (parte-todo), as demais correlações são fracas: gols do mandante e gols do visitante praticamente não se correlacionam ($r \approx 0,01$), indicando que o desempenho ofensivo de um time não depende do desempenho do adversário — cada equipe ataca de forma relativamente independente. O público (Attendance) tem correlação fraca e negativa com os gols do mandante ($r \approx -0,12$), sugerindo que estádios cheios não estão associados a mais gols do time da casa. No gráfico de dispersão Ano x Público nota-se uma tendência não linear: crescimento acentuado até os anos 1970-1990 (popularização global do futebol e maior capacidade dos estádios) seguido de estabilização/leve queda nas últimas edições, quando estádios modernos priorizam conforto a capacidade máxima.

Etapa 5 — Multicolinearidade

```
c = corr.abs()
pairs = c.where(np.triu(np.ones(c.shape), k=1).astype(bool)).stack()
print(pairs[pairs > 0.5].sort_values(ascending=False))
```

Apenas dois pares superam o limiar de $|r| > 0,5$: Gols do Mandante x Gols 1ºT do Mandante (0,73) e Gols do Visitante x Gols 1ºT do Visitante (0,69). Esses pares não configuram multicolinearidade problemática no sentido estatístico clássico (redundância entre preditores independentes), pois há uma relação de causalidade/composição óbvia — o gol do intervalo é um subconjunto do gol final. Em um eventual modelo preditivo que use o placar final como alvo, seria necessário excluir os gols do intervalo das variáveis explicativas (ou usá-los como proxy de 'ritmo do jogo', nunca os dois simultaneamente), evitando vazamento de informação (data leakage) e redundância. As demais variáveis numéricas (Attendance, Year) não apresentam colinearidade relevante com as demais, podendo ser usadas livremente em conjunto.

Etapa 6 — Visualização Multivariada

```
df["Total.Goals"] = df["Home.Team.Goals"] + df["Away.Team.Goals"]
df["Is.Final"] = df["Stage"].isin(["Final", "Match for third place", ...])

sns.scatterplot(data=df, x="Year", y="Total.Goals",
               hue="Is.Final", size="Attendance")

sns.boxplot(data=df[df.Stage.isin(top_stages)], x="Stage", y="Attendance")

sns.pairplot(df[...].assign(Epoca=pd.cut(df.Year, ...)), hue="Epoca")
```




Figura 6 — Gols totais por partida ao longo dos anos, com cor indicando jogos de fase final e tamanho representando o público.

O total de gols por partida (soma dos dois times) não mostra tendência clara de queda ou alta ao longo do século — o futebol se manteve estatisticamente estável em média de gols, oscilando entre 2 e 3 por jogo na maioria das décadas, com exceção das Copas de 1930-1954, mais ofensivas. Partidas de fase final (semifinais, final, disputa de 3º lugar) tendem a ter público mais alto (bolhas maiores), como esperado, mas não necessariamente mais gols — muitas finais são jogos truncados e defensivos.




Figura 7 — Público por fase da competição (6 fases mais frequentes).

Fica evidente uma heterogeneidade forte entre fases: a fase de 'Group A/B/C...' (grupos modernos) tem mediana de público mais baixa e menor variabilidade, enquanto 'Round of 16' e fases de mata-mata concentram jogos com público mais alto e mais disperso — reflexo de partidas em estádios maiores e maior interesse do torcedor à medida que a competição avança.




Figura 8 — Pairplot de Gols Mandante, Gols Visitante e Público, segmentado por época do torneio.

O pairplot segmentado por época (1930-1966, 1970-1994, 1998-2014) revela que a época mais antiga (verde/roxo, conforme paleta) concentra placares mais altos e mais dispersos, enquanto a época mais recente mostra distribuições mais 'comprimidas' em torno de placares baixos (1 a 2 gols) — evidência visual de que o futebol se tornou tático e defensivamente mais equilibrado ao longo do tempo. O público também aumenta de patamar entre as épocas, consistente com a expansão global do torneio.

Etapa 7 — Descobertas Estatísticas Marcantes

Fenômeno 1 — Assimetria severa nas variáveis de gols

Todas as variáveis de contagem de gols (mandante, visitante, 1º tempo) apresentam assimetria positiva forte (0,7 a 2,0), evidenciada nos histogramas da Etapa 3 e nas medidas de moda=0 ou 1 muito abaixo da média. Isso reflete a natureza do futebol como esporte de baixo placar: a maioria dos jogos tem poucos gols, e goleadas (9x0, 10x1) são eventos raros que puxam a cauda da distribuição para a direita.

Fenômeno 2 — Heterogeneidade entre fases da competição

A Etapa 6 mostrou que o público varia sistematicamente por fase do torneio (grupos vs. mata-mata), com medianas e dispersões distintas — não é uma variável homogênea, mas sim um conjunto de subpopulações com comportamentos diferentes, o que reforça a importância de sempre segmentar análises de público por fase/época, e não tratar a Copa como um bloco uniforme.

Fenômeno 3 — Relação estrutural (não redundância real) entre gols parciais e finais

A Etapa 5 identificou as únicas correlações fortes da base entre gols no intervalo e gols finais ($r \approx 0,7$). Diferente de uma colinearidade espúria, trata-se de uma relação lógica de composição, um alerta importante para qualquer modelagem futura evitar vazamento de dados.

Fenômeno 4 — Mudança de padrão de jogo ao longo das décadas

O pairplot por época (Etapa 6) evidenciou um deslocamento visual dos placares ao longo do tempo: Copas mais antigas (1930-1966) tinham distribuições de gols mais dispersas e com placares elevados; Copas recentes mostram jogos mais equilibrados e defensivos — um padrão histórico-tático consistente com a profissionalização e o maior nivelamento técnico entre seleções.